

PCA sulle Curve dei Tassi di Interesse (ECB)

Teoria, Implementazione in R e Interpretazione Economica

Gregorio Pellegrini

Indice

1	Introduzione e obiettivi	2
1.1	La curva dei tassi e il problema della dimensionalità	2
1.2	Origine dei dati	3
2	Prerequisiti matematici: SVD e approssimazione ottimale	3
2.1	Decomposizione ai Valori Singolari (SVD)	3
2.2	La norma di Frobenius	5
2.3	Il teorema di Eckart–Young–Mirsky: ottimalità della SVD troncata	5
2.4	PCA come SVD della matrice centrata	5
3	Applicazione della PCA e SVD ai tassi di interesse ECB	6
3.1	Dati, aggregazione mensile e analisi esplorativa	6
3.1.1	Perché variazioni mensili?	6
3.1.2	Lettura, pulizia e aggregazione mensile	7
3.1.3	Grafico dei livelli mensili	8
3.1.4	Variazioni mensili: la matrice ΔR^{mens}	8
3.1.5	Matrice di correlazione mensile	9
3.2	PCA tramite SVD	9
3.2.1	Costruzione della matrice centrata e SVD	9
3.3	Interpretazione e ricostruzione	11
3.3.1	I loadings: forma dei fattori sulla curva	11
3.3.2	Interpretazione economica dei tre fattori	11
3.3.3	Gli scores mensili: la storia della politica monetaria BCE	11
3.3.4	Ricostruzione della variazione mensile	13
3.3.5	Codice R: ricostruzione e selezione dei mesi rappresentativi	15
3.4	Riepilogo dell’algoritmo completo	16
4	Calibrazione degli scores su una curva arbitraria	16
4.1	Proiezione ortogonale e pesi algebrici	17
4.2	Applicazione: ricostruzione curva ECB Luglio 2026	17
5	Applicazioni pratiche	21
6	Conclusioni	21

1. Introduzione e obiettivi

1.1. La curva dei tassi e il problema della dimensionalità

La **curva dei tassi di interesse** (o struttura a termine) associa a ogni scadenza T un tasso di rendimento $r(T)$ per titoli privi di rischio. La curva cambia ogni giorno in risposta a decisioni di politica monetaria, aspettative di inflazione e fattori macroeconomici.




Figura 1: Esempio di curva dei tassi di interesse. In ascissa la **scadenza** (o *tenor/maturity*) T , espressa in anni; in ordinata il **tasso di interesse** (%) che si riceve investendo fino a quella scadenza un'unità di denaro. Ogni punto della curva è quindi un tasso diverso, uno per ciascuna maturity considerata.

In questa dispensa analizziamo i dati mensili della **curva dei tassi governativi dell'area Euro**, pubblicati dalla Banca Centrale Europea (ECB): si tratta della curva dei rendimenti che la BCE stima ogni giorno a partire da un paniere di titoli di Stato dei paesi dell'area euro con il rating creditizio più elevato (**AAA**, ad es. Germania, Paesi Bassi, Finlandia), ed è comunemente usata come approssimazione del tasso privo di rischio dell'area euro. Consideriamo le scadenze da 1 a 20 anni. L'obiettivo è comprendere e sintetizzare i principali movimenti osservati nella curva nel corso del tempo.

Monitorare direttamente tutte le scadenze della curva richiederebbe di gestire almeno 20 variabili (una per ogni maturity T) e, in contesti come quello attuariale, questo numero può salire a 40 o 50. Analizzare e interpretare così tante variabili è complesso e poco pratico.

Per questo motivo, è utile cercare una rappresentazione più compatta, individuando i *movimenti fondamentali* della curva che, combinati tra loro, spiegano la maggior parte delle variazioni osservate.

In questa dispensa presentiamo la **Principal Component Analysis (PCA)**, implementata tramite la **Singular Value Decomposition (SVD)**, che permette di identificare e quantificare le principali variazioni della curva dei tassi. Vedremo come, grazie a questa tecnica, sia possibile descrivere l'evoluzione della curva nel tempo utilizzando un numero limitato di componenti, facilitando l'analisi e l'interpretazione dei dati.

Nella dispensa è inoltre riportato il codice utilizzato per l'elaborazione dei dati. A tal fine è stato impiegato il software statistico R, una piattaforma gratuita che mette a disposizione numerosi pacchetti specifici per l'analisi dei dati e la trattazione di queste tematiche.

1.2. Origine dei dati

I dati provengono dall'**ECB Data Portal**¹ e rappresentano la **spot rate curve** stimata dalla Banca Centrale Europea su un campione di titoli di Stato dell'area Euro con **rating AAA** (Germania, Paesi Bassi, Finlandia, ecc.).

Con il termine *spot rate* si intende, per ciascuna scadenza T , il tasso di interesse implicito nel prezzo di uno zero-coupon bond che paga un'unità di valuta al tempo T . Formalmente, indicando con $P(0, T)$ il prezzo oggi di tale titolo, lo spot rate $r(T)$ in capitalizzazione continua è definito da

$$P(0, T) = e^{-r(T)T}.$$

Uno *zero-coupon bond* è un titolo privo di cedole che paga un'unica somma, pari al valore nominale, alla scadenza T (detta anche *maturity*); il prezzo pagato oggi per acquistarlo, $P(0, T)$, è inferiore al valore nominale, e la differenza remunera l'investitore sotto forma di interesse. La curva degli spot rate rappresenta quindi la struttura a termine dei tassi di interesse priva di arbitraggio (con *arbitraggio* si intende la possibilità di realizzare un profitto certo senza assumersi alcun rischio: una curva priva di arbitraggio esclude tale possibilità), dalla quale è possibile ricavare i prezzi di qualsiasi cash-flow deterministico.

È prassi comune in matematica finanziaria esprimere le variazioni dei tassi di interesse in **punti base** (*basis point*, **pb**), dove 1 pb equivale a 0,01%.

2. Prerequisiti matematici: SVD e approssimazione ottimale

In questa sezione presentiamo gli strumenti matematici necessari per la PCA; enunceremo i teoremi senza fornirne la dimostrazione.

Il nucleo della trattazione consiste nel chiedersi: data una matrice $X \in \mathbb{R}^{m \times n}$, dove le righe rappresentano per esempio le variazioni mensili della curva dei tassi, con m mesi e n scadenze, come possiamo rappresentarla in modo *compatto* usando solo $k \ll n$ “direzioni” fondamentali, perdendo la minima quantità possibile di informazione?

La trattazione passa attraverso tre risultati:

1. la **SVD** fattorizza qualsiasi matrice in componenti ordinate per importanza;
2. il teorema di **Eckart–Young–Mirsky** garantisce che troncando la SVD alle prime k componenti dà la migliore approssimazione possibile di rango k ;
3. la **norma di Frobenius** usata nel precedente teorema coincide (a meno di costanti) con la *varianza totale* del campione di misurazioni.

2.1. Decomposizione ai Valori Singolari (SVD)

Teorema 2.1 (Esistenza e unicità della SVD). *Per ogni matrice $A \in \mathbb{R}^{m \times n}$ esistono:*

- una matrice ortogonale $U \in \mathbb{R}^{m \times m}$ (colonne = **vettori singolari sinistri**);
- una matrice ortogonale $V \in \mathbb{R}^{n \times n}$ (colonne = **vettori singolari destri**);
- una matrice diagonale $\Sigma \in \mathbb{R}^{m \times n}$ con elementi $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$ (**valori singolari**);

tali che $A = U\Sigma V^T$. I valori singolari sono unici; i vettori singolari sono unici a meno di segno quando i σ_i sono distinti.

¹<https://data.ecb.europa.eu>, dataset *YC – Euro area yield curves*.

Interpretazione geometrica. La Figura 2 illustra come agisce la SVD su un esempio 2×2 concreto: la matrice di taglio (*shear*)

$$A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}. \quad (1)$$

I due vettori evidenziati in figura sono $\mathbf{v}_1, \mathbf{v}_2$, le colonne di V . La matrice A trasforma il cerchio unitario in un'ellisse (pannello in alto), i cui semiassi giacciono nelle direzioni date dalle colonne di U . Si può infatti decomporre A come l'azione di tre trasformazioni:

- V^T ruota il cerchio: poiché $V^T V = I$, i vettori $\mathbf{v}_1, \mathbf{v}_2$ diventano *esattamente* gli assi principali $\mathbf{e}_1, \mathbf{e}_2$;
- Σ allunga lungo gli assi di un fattore $\sigma_1 \approx 1,618$ e $\sigma_2 \approx 0,618$, producendo un'ellisse allineata agli assi, con semiassi $\sigma_1 \mathbf{e}_1, \sigma_2 \mathbf{e}_2$;
- infine U ruota quest'ultima nella posizione finale allineando i semiassi dell'ellisse alle direzioni date dalle colonne di U .




Figura 2: Interpretazione geometrica della SVD

I valori singolari σ_i misurano quanto A “allunga” lungo ciascun asse principale: σ_1 è la direzione di massimo allungamento, σ_n quella di minimo.

2.2. La norma di Frobenius

Definiamo la **norma di Frobenius** come segue:

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\text{tr}(A^T A)}.$$

Proposizione 2.2 (Frobenius e valori singolari). *Per ogni matrice A con valori singolari $\sigma_1, \dots, \sigma_r$ (dove $r = \text{rk}(A)$):*

$$\|A\|_F^2 = \sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2. \quad (2)$$

2.3. Il teorema di Eckart–Young–Mirsky: ottimalità della SVD troncata

Teorema 2.3 (Eckart–Young–Mirsky, 1936). *Sia $A = U\Sigma V^T$ la SVD di A , e sia*

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = U_k \Sigma_k V_k^T$$

*la **SVD troncata** alle prime k componenti. Allora A_k è la **miglior approssimazione di rango k** in norma di Frobenius:*

$$A_k = \underset{\text{rk}(B) \leq k}{\text{argmin}} \|A - B\|_F.$$

Inoltre, l'errore di approssimazione è:

$$\|A - A_k\|_F^2 = \sigma_{k+1}^2 + \dots + \sigma_r^2. \quad (3)$$

2.4. PCA come SVD della matrice centrata

Applichiamo ora i risultati appena visti — SVD, Eckart–Young e norma di Frobenius — per costruire formalmente la PCA. La matrice $X \in \mathbb{R}^{m \times n}$ a cui si applica la PCA rappresenta una matrice che raccoglie le osservazioni su più dimensioni di un fenomeno per cui si vuole ridurre la dimensionalità. Nella nostra applicazione, X sarà la matrice le cui m righe sono le osservazioni (ad esempio i mesi per cui sono misurati i valori del tasso di interesse) e le cui n colonne sono le variabili osservate (le scadenze).

Definizione 2.4 (Matrice centrata). Data $X \in \mathbb{R}^{m \times n}$, la **matrice centrata** è:

$$\tilde{X} = X - \mathbf{1}_m \bar{\mathbf{x}}^T,$$

dove $\bar{\mathbf{x}} \in \mathbb{R}^n$ è il vettore delle medie per colonna.

E' buona prassi quando si ha un campione di osservazioni, come sarà nel nostro caso, togliere la media al campione per ogni scadenza, come definito con la matrice centrata $\tilde{X}$, in modo da co-centrarsi su un dataset a media nulla isolando le così le direzioni di massima variabilità.

La varianza campionaria di $\tilde{X}$ è definita come:

$$\text{Var}_{\text{tot}} = \frac{1}{m-1} \sum_{i,j} \tilde{x}_{ij}^2 = \frac{\|\tilde{X}\|_F^2}{m-1}. \quad (4)$$

Quindi $\|\tilde{X}\|_F^2 = (m-1) \cdot \text{Var}_{\text{tot}}$, da (2) segue che la norma di Frobenius rappresenta la varianza totale, a meno di una costante.

Possiamo ora definire la Principal Component Analysis (PCA) calcolata sul set di osservazioni $\tilde{X}$.

Teorema 2.5 (Principal Component Analysis). *Sia $\tilde{X} = U\Sigma V^T$ la SVD della matrice centrata. Allora:*

1. *I **loadings** (direzioni principali) sono le colonne di V : $\mathbf{v}_1, \mathbf{v}_2, \dots$*
2. *Gli **scores** (coordinate nelle nuove direzioni) sono le righe di $U\Sigma$, cioè $\tilde{X}V$.*
3. *La varianza spiegata dalla componente i è $\sigma_i^2 / \sum_j \sigma_j^2$.*

Per il Teorema 2.3 (Eckart–Young), considerando $k < n$ componenti principali, $\tilde{X}_k$ è la miglior approssimazione di rango k di $\tilde{X}$ in norma di Frobenius, con errore residuo:

$$\|\tilde{X} - \tilde{X}_k\|_F^2 = \sigma_{k+1}^2 + \dots + \sigma_n^2. \quad (5)$$

Combinando (4) e (5), possiamo definire la **quota di varianza spiegata** dalle prime k componenti come:

$$\eta_k = \frac{\|\tilde{X}_k\|_F^2}{\|\tilde{X}\|_F^2} = \frac{\sigma_1^2 + \dots + \sigma_k^2}{\sigma_1^2 + \dots + \sigma_n^2} = 1 - \frac{\sigma_{k+1}^2 + \dots + \sigma_n^2}{\sigma_1^2 + \dots + \sigma_n^2} \in [0, 1]. \quad (6)$$

Quindi la SVD troncata di $\tilde{X}$ alle prime k componenti costituisce un'approssimazione del set di osservazioni originali. Considerando la definizione $\tilde{X}_k = U_k \Sigma_k V_k^T$, la s -esima riga di $\tilde{X}_k$ rappresenta l'approssimazione k -dimensionale della s -esima riga di $\tilde{X}$. $U_k \in \mathbb{R}^{m \times k}$ e $V_k \in \mathbb{R}^{n \times k}$ raccolgono rispettivamente le prime k colonne di U e V , ed è possibile riscriverla come segue:

$$(\tilde{X}_k)_{s,:} = \hat{\mathbf{x}}_s^{(k)} = \sum_{i=1}^k \alpha_{s,i} \mathbf{v}_i = V_k \boldsymbol{\alpha}_{s,k} \in \mathbb{R}^n, \quad \alpha_{s,i} = \sigma_i u_{s,i} = (U\Sigma)_{s,i}. \quad (7)$$

ovvero i vettori $\mathbf{v}_i$ indicano le direzioni lungo cui spostarsi, con ampiezza $\alpha_{s,i}$, per ottenere lo spostamento complessivo.

3. Applicazione della PCA e SVD ai tassi di interesse ECB

In questa sezione applichiamo la teoria sviluppata nella sezione precedente alla curva dei tassi ECB. Il percorso si articola in quattro fasi: preparazione dei dati e analisi esplorativa, decomposizione tramite SVD, interpretazione economica dei fattori e ricostruzione della curva, infine un riepilogo dell'algoritmo.

3.1. Dati, aggregazione mensile e analisi esplorativa

3.1.1. Perché variazioni mensili?

Dal punto di vista dell'analisi economica, l'obiettivo non è quello di catturare movimenti di brevissimo periodo o dinamiche di microstruttura, bensì di descrivere l'evoluzione della curva dei rendimenti su orizzonti temporali più ampi, rilevanti per analisi prospettiche e di scenario. In questo contesto, l'utilizzo di variazioni giornaliere risulta più adatto ad applicazioni di trading o gestione operativa ad alta frequenza, mentre offre un contenuto informativo limitato per un'analisi strutturale dei fattori della curva.

Ci concentriamo dunque sull'analisi delle osservazioni mensili, che permettono di cogliere chiaramente i principali eventi macro-finanziari, quali la crisi di Lehman Brothers (2008), il Quantitative Easing della BCE (2015–2018) e il ciclo di rialzi dei tassi del 2022.

3.1.2. Lettura, pulizia e aggregazione mensile

Il codice seguente carica i dati giornalieri, li pulisce e li riduce all'ultima osservazione di ogni mese. Formalmente, la matrice mensile è:

$$R_{s,j}^{\text{mens}} = R_{t^*(s),j}, \quad t^*(s) = \max\{t : t \in \text{mese } s\},$$

dove s indicizza i mesi e $j \in \{1, \dots, 20\}$ le scadenze. La matrice risultante è $R^{\text{mens}} \in \mathbb{R}^{M \times 20}$ con $M \approx 260$ mesi.

Lettura e aggregazione mensile (03b_pca_ecb.R)

```
library(data.table); library(openxlsx); library(lubridate); library(ggplot2)

curve_df <- as.data.table(
  read.xlsx("../dati/03_ecb_spot.xlsx", sheet = "PCA_Input"))

# ... parsing date e interpolazione NA

# I tassi vengono convertiti in DECIMALI: 2.592 (%) -> 0.02592
for (cc in maturity_cols) curve_df[, (cc) := as.numeric(get(cc)) / 100]

# ---- Aggregazione mensile ----
# floor_date("2022-10-17", "month") restituisce "2022-10-01"
# .SD[.N] seleziona l'ultima riga di ogni gruppo -> fine mese effettivo
curve_df[, YM := floor_date(TIME_PERIOD, "month")]
monthly_dt <- curve_df[, .SD[.N], by = YM,
  .SDcols = c("TIME_PERIOD", maturity_cols)]
setorder(monthly_dt, YM)

# ---- Matrici di lavoro ----
R_mat_m <- as.matrix(monthly_dt[, ..maturity_cols]) # M x n
dates_m <- monthly_dt$TIME_PERIOD # fine mese effettiva (M)
Delta_R_m <- diff(R_mat_m) # (M-1) x n
dates_delta_m <- dates_m[-1]

# Chiave "anno_mese" per selezionare i mesi in modo leggibile
monthly_dt[, anno := year(TIME_PERIOD)]
monthly_dt[, mese := month(TIME_PERIOD)]
monthly_dt[, periodo := paste0(anno, "_", mese)]
```

Osservazione. La scelta di prendere l'*ultima* osservazione (e non la media mensile) è standard nella gestione del rischio di tasso: riflette il prezzo al quale si chiude il mese e sul quale si calcolano i P&L mensili dei portafogli obbligazionari.

3.1.3. Grafico dei livelli mensili




Figura 3: Curve dei tassi ECB in tre mesi all'interno del campione. L'asse x indica la scadenza in anni, l'asse y il tasso in %.

3.1.4. Variazioni mensili: la matrice ΔR^{mens}

La PCA si applica alle *variazioni* della curva, non ai livelli:

$$(\Delta R^{\text{mens}})_{s,j} = R_{s,j}^{\text{mens}} - R_{s-1,j}^{\text{mens}}, \quad s = 2, \dots, M, \quad j = 1, \dots, n.$$

Applicare la PCA ai livelli R^{mens} sarebbe tecnicamente possibile, e in letteratura la scelta fra livelli e variazioni è oggetto di discussione: sui livelli si trovano ad esempio PCA usate per approssimare la *forma* della curva (es. curve parametriche sintetiche), dove l'obiettivo non è descrivere i movimenti ma la forma stessa.

Per l'analisi del rischio di tasso, lo standard consolidato fin da Litterman & Scheinkman [4] è lavorare sulle **variazioni** ΔR , non sui livelli. Il motivo è essenzialmente statistico: i tassi di interesse sono tipicamente non stazionari (spesso modellati come moti browniani con drift), mentre le loro variazioni sono stazionarie o quasi-stazionarie, condizione su cui la PCA si fonda per dare loadings stabili e non dipendenti dal periodo campionario scelto. Le variazioni sono inoltre l'input naturale per il calcolo del P&L e del VaR di un portafoglio obbligazionario [5]: i tre fattori PCA estratti da ΔR — livello, pendenza, curvatura — hanno quindi un significato operativo diretto, direttamente raccordabile con uno scenario di stress. In questa dispensa seguiamo questa prassi, analizzando ΔR^{mens} .

Le variazioni mensili hanno un range tipico di **20–80 punti base** nei periodi normali, e fino a **150–200 pb** negli episodi di shock monetario. Questo ordine di grandezza le rende direttamente interpretabili e confrontabili con le decisioni di politica monetaria BCE (ad es. rialzo di 75 pb a ottobre 2022).




Figura 4: **Distribuzione delle variazioni mensili** $\Delta R^{\text{mens}}(T_j)$ per ciascuna scadenza, espressa in punti base (1 pb = 0.01%). Le distribuzioni sono nettamente più informative: le mediane si discostano visibilmente da zero nei periodi di trend come per esempio politiche della banca centrale di rialzo dei tassi, gli IQR catturano la volatilità ciclica tipica di ogni scadenza, e la struttura del segnale domina il rumore. La variabilità è maggiore alle scadenze intermedie-lunghe, indice del fatto che i movimenti di curvatura e pendenza si manifestano principalmente sul tratto 2–10 anni.

3.1.5. Matrice di correlazione mensile




Figura 5: Correlazione tra variazioni mensili visualizzata in due modi complementari: heat-map (sinistra) e superficie a barre 3D (destra).

3.2. PCA tramite SVD

3.2.1. Costruzione della matrice centrata e SVD

Applicando il Teorema 2.5 alla matrice mensile:

Centraggio e SVD su dati mensili

```
# Media di colonna delle variazioni mensili (il vettore x barra)
xm <- rep(0, length(maturity_cols))
for (i in c(1:length(maturity_cols))) {
  xm[i] <- mean(Delta_R_m[, i])
}

# Matrice centrata: si sottrae la media di colonna a ogni riga
X_m = Delta_R_m - matrix(rep(xm, nrow(Delta_R_m)),
                          nrow = nrow(Delta_R_m), byrow = TRUE)

sv_m      <- svd(X_m)
sing_vals <- sv_m$d
V <- sv_m$v
U <- sv_m$u
k = 3

loadings  <- V[, 1:k]           # una direzione per componente
scores_all <- U %*% diag(sing_vals)
scores    <- scores_all[, 1:k]  # tre pesi per ogni mese

expl_var <- sing_vals^2 / sum(sing_vals^2)
cum_var  <- cumsum(expl_var)
```




Figura 6: Varianza per componente e varianza cumulata. Barre blu: varianza individuale per componente; linea rossa: varianza cumulata, con etichette per le prime tre componenti.

Nel seguito adottiamo $k = 3$ componenti principali, che, come vedremo successivamente, sono direttamente interpretabili in termini economici (livello, pendenza, curvatura). Con questa scelta le prime tre componenti principali spiegano $\eta_3 = 99.52\%$ della varianza totale del campione, una quota che rende trascurabile il contributo delle componenti residue.

3.3. Interpretazione e ricostruzione

3.3.1. I loadings: forma dei fattori sulla curva

I loadings $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3 \in \mathbb{R}^n$ rappresentano le direzioni principali rispetto alle quali decomporre la variazione mensile dei tassi di interesse.




Figura 7: Loadings delle prime tre componenti in funzione della scadenza (anni). PC1 piatta (livello), PC2 monotona (pendenza), PC3 a gobba (curvatura).

3.3.2. Interpretazione economica dei tre fattori

Fattore	Tipo	Forma del loading	Interpretazione	Var. tipica
PC1	Livello	Stesso segno e valore simile per tutte le scadenze	Shift parallelo: tutti i tassi salgono o scendono insieme	70–80%
PC2	Pendenza	Un cambio di segno: negativo (breve) / positivo (lungo)	Rotazione: tassi brevi e lunghi in direzioni opposte	10–15%
PC3	Curvatura	Due cambi di segno: positivo agli estremi, negativo al centro	Butterfly: il ventre si muove in senso opposto agli estremi	3–7%

3.3.3. Gli scores mensili: la storia della politica monetaria BCE

Dopo la decomposizione $\tilde{X} = U\Sigma V^T$, gli **scores** $\alpha_{s,i} = \sigma_i u_{s,i}$, già definiti in (7), si raccolgono nella matrice $U\Sigma \in \mathbb{R}^{(M-1) \times n}$. Lo score $\alpha_{s,i}$ misura *di quanto* la curva si è mossa nel mese s nella direzione del loading $\mathbf{v}_i$: un valore grande (in modulo) indica che quel fattore ha dominato il movimento; un valore vicino a zero indica che il fattore era inattivo.

La Figura 8 sovrappone a ciascuno score (linea chiara) la sua media mobile a 6 mesi (linea blu scura), che filtra le oscillazioni di breve periodo e rende più leggibile l'andamento generale degli scores.




Figura 8: Scores mensili PC1, PC2, PC3: serie grezza (linea chiara) e media mobile a 6 mesi (linea blu scura), con marcatura degli eventi macroeconomici principali (linee tratteggiate grigie).

La Figura 8 permette di seguire con chiarezza il trend di ciascun fattore attraverso i principali episodi macro-finanziari del campione:

- **Crisi di Lehman Brothers (autunno 2008 – inizio 2009).** PC1 crolla in più mesi consecutivi (tra i cali più marcati del campione, ad es. novembre 2008): i tassi scendono in blocco. Il movimento non è però uniforme lungo la curva. Nei due mesi immediatamente successivi al fallimento (settembre e ottobre 2008) il calo è concentrato sulle scadenze brevi — il tasso a 1 anno perde oltre 60 punti base in un solo mese, contro variazioni quasi nulle sul 10 anni — un *irripidimento* colto da PC2, fortemente negativo in quei due mesi. A gennaio 2009 PC2 tocca il valore più estremo dell'intero campione: il tasso a 1 anno continua a scendere mentre i tassi a 10 e 20 anni risalgono bruscamente, un violento irripidimento della curva. Nello stesso periodo anche PC3 (curvatura) raggiunge a ottobre 2008 il proprio massimo assoluto sull'intero campione: le scadenze intermedie (5–10 anni) scendono meno delle scadenze molto brevi e di quelle lunghe, segno di una fuga verso la liquidità di brevissimo termine accompagnata da timori deflazionistici sulle scadenze lunghe.
- **Quantitative Easing della BCE (2015–2018).** Il programma di acquisti spinge PC1 in territorio cumulativamente negativo per l'intero periodo: i tassi scendono su tutte le scadenze. Il calo non è però parallelo: sommando gli scores mensili sull'intero periodo, PC3 risulta cumulativamente positivo, a indicare che le scadenze intermedie (5–10 anni) hanno ceduto meno delle due estremità della curva.

- **Rialzi BCE per il contrasto all'inflazione (dal luglio 2022).** A partire dal primo rialzo di luglio 2022, PC1 sale rapidamente fino al valore più alto dell'intero campione (agosto 2022), riflettendo il ciclo di inasprimento monetario più aggressivo dalla nascita dell'euro. Nello stesso bimestre agosto-settembre 2022 PC2 è marcatamente positivo: le scadenze brevi salgono più di quelle lunghe e la curva si appiattisce fino a invertirsi (breve sopra lungo), riflettendo aspettative di rialzi ravvicinati insieme a timori di rallentamento economico che frenano i tassi lunghi.

Con dati giornalieri tutti questi segnali sarebbero sepolti nel rumore.

3.3.4. Ricostruzione della variazione mensile

La variazione mensile del mese s si ricostruisce come combinazione lineare dei loadings, pesati dagli scores:

$$\hat{\Delta r}_s^{(k)} = \underbrace{\bar{\mathbf{x}}}_{\text{media}} + \underbrace{\alpha_{s,1} \mathbf{v}_1}_{\text{livello}} + \underbrace{\alpha_{s,2} \mathbf{v}_2}_{\text{pendenza}} + \cdots + \alpha_{s,k} \mathbf{v}_k \quad (8)$$

dove $\bar{\mathbf{x}} \in \mathbb{R}^n$ è il vettore delle variazioni medie (sottratto prima della decomposizione SVD e aggiunto per riportare nella scala originale), $\alpha_{s,i} = (U\Sigma)_{s,i}$ è lo score, e $\mathbf{v}_i$ il loading.

Consideriamo ora come esempio tre mesi: ottobre 2004 (primo mese), settembre 2015 (centrale) e giugno 2026 (ultimo) per verificare la qualità della ricostruzione su periodi diversi del campione.




Figura 9: Variazione mensile reale vs. ricostruita con $k = 3$ componenti nei tre mesi selezionati (primo, centrale, ultimo). L'asse y è in punti base.

In ciascun pannello della Figura 9, la curva osservata e quella ricostruita sono molto vicine: la PCA a 3 fattori cattura i movimenti principali della curva su tutta la storia del campione. Le discrepanze residue sono associate alle componenti dalla quarta in poi, che spiegano una quota limitata della varianza totale.

Per quantificare dove si concentra questo residuo, la Figura 10 mostra, scadenza per scadenza, la differenza (ricostruita – osservata) in punti base sugli stessi tre mesi.




Figura 10: Errore di ricostruzione (ricostruita – osservata, $k = 3$) per singola scadenza, nei tre mesi selezionati (primo, centrale, ultimo). L'asse y è in punti base.

Per capire il contributo di ciascuna componente, è utile osservare come la curva si ricostruisce aggiungendo un fattore alla volta. Come esempio concreto utilizziamo **giugno 2026**, l'ultimo mese del campione: un mese in cui la curva BCE ha mostrato un movimento non banale, con una componente di pendenza apprezzabile oltre al consueto shift parallelo.




Figura 11: Ricostruzione progressiva della variazione mensile della curva BCE per giugno 2026, aggiungendo una componente alla volta. La curva nera è la variazione reale osservata (in punti base).

La Figura 11 mostra come ogni fattore contribuisce alla ricostruzione. Per giugno 2026 gli scores sono $\alpha_{s,1} \approx -34,7$ pb, $\alpha_{s,2} \approx +8,6$ pb e $\alpha_{s,3} \approx -2,7$ pb: $k = 1$ (**+livello**): lo score $\alpha_{s,1}$, il più grande in modulo, aggiunge lo shift parallelo dominante — già la maggior parte del movimento viene spiegata. $k = 2$ (**+pendenza**): lo score $\alpha_{s,2}$, circa un quarto del precedente, corregge la rotazione breve-lungo, catturando la differenza di movimento tra scadenze corte e lunghe. $k = 3$ (**+curvatura**): lo score $\alpha_{s,3}$, piccolo ma non nullo, affina il profilo del ventre, riducendo ulteriormente il residuo. La percentuale tra parentesi in legenda è la varianza cumulata spiegata sull'intero campione da quella componente.

3.3.5. Codice R: ricostruzione e selezione dei mesi rappresentativi

Ricostruzione della variazione di un singolo mese

```
# Il "-1" serve perche' diff() ha rimosso la prima riga: la riga s di
# Delta_R_m corrisponde al mese s+1 di monthly_dt.
mese2      <- '2015_9'
row_number2 <- which(monthly_dt$periodo == mese2) - 1
delta_dati2 <- Delta_R_m[row_number2, ]

# Ricostruzione: media + combinazione lineare dei tre loadings,
# pesati dagli scores del mese
delta_ricostrito2 <- xm +
  scores[row_number2, 1] * loadings[, 1] +
  scores[row_number2, 2] * loadings[, 2] +
  scores[row_number2, 3] * loadings[, 3]

confronto_settembre2015 <- data.table(
  maturity      = maturity_num,
  x_m_originale = delta_dati2,
  x_m_ricostruito = delta_ricostrito2,
  delta_bp      = (delta_ricostrito2 - delta_dati2) * 1e4)
```

3.4. Riepilogo dell'algoritmo completo

PCA mensile della curva dei tassi BCE (in R)

```
# INPUT: curve_df con colonne TIME_PERIOD, 1Y, ..., 20Y (in decimali)

# 1. Aggregazione mensile (ultima osservazione di ogni mese)
curve_df[, YM := floor_date(TIME_PERIOD, "month")]
monthly_dt <- curve_df[, .SD[.N], by = YM, .SDcols = c("TIME_PERIOD", maturity_cols)]

# 2. Matrice dei livelli e variazioni mensili
R_mat_m <- as.matrix(monthly_dt[, ..maturity_cols]) # M x n
Delta_R_m <- diff(R_mat_m) # (M-1) x n

# 3. Centraggio per colonna
xm <- rep(0, length(maturity_cols))
for (i in c(1:length(maturity_cols))) xm[i] <- mean(Delta_R_m[, i])
X_m = Delta_R_m - matrix(rep(xm, nrow(Delta_R_m)),
                          nrow = nrow(Delta_R_m), byrow = TRUE)

# 4. SVD della matrice centrata
sv_m <- svd(X_m) # sv_m$u, sv_m$d, sv_m$v
V <- sv_m$v ; U <- sv_m$u ; sing_vals <- sv_m$d

# 5. Varianza spiegata
expl_var <- sing_vals^2 / sum(sing_vals^2)
cum_var <- cumsum(expl_var)

# 6. Loadings e scores (k = 3)
k = 3
loadings <- V[, 1:k]
scores <- (U %*% diag(sing_vals))[, 1:k]

# 7. Ricostruzione della variazione di un mese
row_s <- which(monthly_dt$periodo == '2015_9') - 1
delta_ricostruito <- xm + scores[row_s, 1] * loadings[, 1] +
                    scores[row_s, 2] * loadings[, 2] +
                    scores[row_s, 3] * loadings[, 3]

# 8. Calibrazione su una curva nuova (fuori campione): si proietta
# direttamente la curva, senza passare da un delta di riferimento
Vk <- V[, 1:k, drop = FALSE]
alpha <- t(Vk) %*% y_new
y_hat <- Vk %*% alpha
```

4. Calibrazione degli scores su una curva arbitraria

Una volta stimata la matrice dei loadings V dalla PCA storica, è possibile *proiettare* un nuovo vettore $\mathbf{y} \in \mathbb{R}^n$ sullo spazio generato dalle prime k componenti principali, ottenendo k **pesi** (scores) e una **ricostruzione approssimata**. Con $k = n$ (base completa) la ricostruzione è esatta.

4.1. Proiezione ortogonale e pesi algebrici

Siano $\mathbf{v}_1, \dots, \mathbf{v}_n \in \mathbb{R}^n$ i vettori colonna di V — le colonne ortonormali della SVD di $\tilde{X}$, cioè i **loadings PCA**. Essi formano una base ortonormale di $\mathbb{R}^n$:

$$V^T V = I_n, \quad V \in \mathbb{R}^{n \times n}.$$

Dati i primi $k \leq n$ loadings $V_k = [\mathbf{v}_1 \mid \dots \mid \mathbf{v}_k] \in \mathbb{R}^{n \times k}$, la ricostruzione di $\mathbf{y}$ con k componenti si ottiene in due passi:

Passo 1 — Calcolo dei pesi (scores): si proietta $\mathbf{y}$ su ciascuna direzione principale:

$$\boldsymbol{\alpha}_k = V_k^T \mathbf{y} = \begin{pmatrix} \mathbf{v}_1^T \mathbf{y} \\ \vdots \\ \mathbf{v}_k^T \mathbf{y} \end{pmatrix} \in \mathbb{R}^k.$$

Ogni componente $\alpha_i = \mathbf{v}_i^T \mathbf{y}$ è il prodotto scalare tra $\mathbf{y}$ e il loading $\mathbf{v}_i$: misura “quanto” di $\mathbf{y}$ sta nella direzione i -esima.

Passo 2 — Ricostruzione: si combinano linearmente i loadings con i pesi appena calcolati:

$$\hat{\mathbf{y}}^{(k)} = V_k \boldsymbol{\alpha}_k = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k \in \mathbb{R}^n.$$

In forma compatta, essendo $\boldsymbol{\alpha}_k = V_k^T \mathbf{y}$:

$$\hat{\mathbf{y}}^{(k)} = V_k (V_k^T \mathbf{y}) = (V_k V_k^T) \mathbf{y}.$$

La matrice $P_k = V_k V_k^T \in \mathbb{R}^{n \times n}$ è il **proiettore ortogonale** sullo spazio generato dalle prime k colonne di V .

Osservazione. Per $k = n$ vale $V_n V_n^T = I_n$ (base completa), quindi $\hat{\mathbf{y}}^{(n)} = \mathbf{y}$ e l'errore di ricostruzione è zero. La curva viene recuperata *esattamente* combinando tutti i loadings.

4.2. Applicazione: ricostruzione curva ECB Luglio 2026

Il campione principale arriva fino a giugno 2026: per un esempio genuinamente fuori campione consideriamo la curva spot BCE del **30 luglio 2026**. Come osservato nella sottosezione precedente, le colonne di V formano una base ortonormale completa di $\mathbb{R}^{20}$: la proiezione è quindi lecita per *qualsiasi* curva, non solo per le variazioni su cui V è stata stimata. Appliciamo perciò direttamente le formule del Passo 1 e Passo 2 alla curva seguente:

Scadenza	1Y	2Y	3Y	4Y	5Y	6Y	7Y	8Y	9Y	10Y	11Y	12Y	13Y	14Y	15Y	16Y	17Y	18Y	19Y	20Y
Tasso (%)	2.615	2.713	2.757	2.802	2.857	2.922	2.992	3.064	3.134	3.201	3.263	3.321	3.374	3.421	3.464	3.501	3.534	3.562	3.586	3.606

Ricostruzione della curva ECB del 30/07/2026

```
# Curva target, fuori campione (foglio PCA_Input, una sola riga)
y_new <- as.numeric(read.xlsx("04_ecb_spot_20260730.xlsx",
                             sheet = "PCA_Input")[, maturity_cols]) / 100

# Proiezione diretta sui primi k loadings (Passo 1 + Passo 2)
k      <- 3
Vk     <- V[, 1:k, drop = FALSE]
alpha  <- t(Vk) %*% y_new           # pesi (scores)
y_hat  <- Vk %*% alpha              # ricostruzione con k componenti

errore_bp <- (y_hat - y_new) * 1e4  # differenza, in punti base
```

La Figura 12 confronta la curva originale con le ricostruzioni a $k = 3$ e $k = 20$. La Figura 13 scompone l'errore a $k = 3$ scadenza per scadenza. La Figura 14 mostra infine come converge l'errore in norma-2 al crescere di k (scala lineare, cosicché anche l'errore numericamente nullo a $k = 20$ resti visibile). I valori salienti: gli scores ottenuti proiettando la curva sui primi tre loadings sono $\alpha_1 \approx 14,26\%$, $\alpha_2 \approx -0,14\%$ e $\alpha_3 \approx -1,18\%$.

Questo risultato è ottimale perché l'errore con $k = 3$ è già sufficientemente basso: con soli tre scores $\alpha_1, \alpha_2, \alpha_3$ si riesce a mantenere il movimento della curva. Nella pratica i loadings sono salvati e ricalibrati tendenzialmente una volta l'anno, per tenere conto dei movimenti avvenuti nel corso dell'anno; per le proiezioni o le ricostruzioni successive bastano poi le tre componenti α salvate. Questo permette di analizzare la curva con sole 3 componenti anziché modellare e considerare i movimenti di 20 componenti contemporaneamente: il modello risulta così molto più leggero, bilanciando correttezza e dimensionalità.

Osservazione. Per $k = 20$ l'errore è numericamente nullo (Figura 14): V è una base ortonormale completa di $\mathbb{R}^{20}$, quindi la ricostruzione con tutti i loadings è *esatta* per costruzione, come già osservato nella Sezione 4 — indipendentemente dal fatto che la curva proiettata sia o meno dello stesso tipo di oggetto (variazione) su cui V è stata stimata.




Figura 12: Ricostruzione della curva ECB (30/07/2026). Curva nera con punti: originale. Verde tratteggiata: ricostruzione con $k = 3$ componenti. Arancio puntinata: ricostruzione con $k = 20$ (base completa), che coincide esattamente con l'originale.

Come sintesi numerica, la Tabella 1 riporta scadenza per scadenza la curva ECB originale, la ricostruzione con $k = 3$ e l'errore.




Figura 13: Errore di ricostruzione per singola scadenza, $k = 3$. Differenza (ricostruita – originale) in punti base per ciascuna scadenza da 1 a 20 anni.




Figura 14: Convergenza dell'errore di ricostruzione (scala lineare). Errore $\varepsilon_k = \|\hat{\mathbf{y}}^{(k)} - \mathbf{y}\|_2$ in punti base per $k = 1, \dots, 20$. Il punto rosso annotato evidenzia il crollo dell'errore a $k = 3$; a $k = 20$ l'errore è visibilmente nullo.

Scadenza	Curva ECB (%)	Ricostruita $k = 3$ (%)	Errore $k = 3$ (bp)
1Y	2.615	2.565	-4.99
2Y	2.713	2.758	+4.50
3Y	2.757	2.784	+2.67
4Y	2.802	2.808	+0.62
5Y	2.857	2.849	-0.84
6Y	2.922	2.905	-1.71
7Y	2.992	2.972	-2.01
8Y	3.064	3.046	-1.82
9Y	3.134	3.121	-1.29
10Y	3.201	3.195	-0.56
11Y	3.263	3.265	+0.20
12Y	3.321	3.330	+0.87
13Y	3.374	3.387	+1.36
14Y	3.421	3.437	+1.61
15Y	3.464	3.479	+1.60
16Y	3.501	3.514	+1.31
17Y	3.534	3.541	+0.78
18Y	3.562	3.562	+0.01
19Y	3.586	3.577	-0.94
20Y	3.606	3.585	-2.06

Tabella 1: Curva ECB (30/07/2026): valori originali, ricostruzione con $k = 3$ componenti ed errore (ricostruita – originale, in punti base).

5. Applicazioni pratiche

1. **Compressione:** il dataset mensile (260 righe $\times$ 20 colonne) si riduce a 3 serie temporali di scores con perdita di informazione inferiore al 5%.
2. **Scenari di stress mensili:** uno shock di $+\sigma_1$ sul fattore livello simula una decisione BCE di rialzo di circa 25–50 pb; identifica immediatamente la sensibilità di un portafoglio obbligazionario.
3. **Hedging fattoriale:** invece di coprirsi contro 20 movimenti indipendenti, si gestisce l'esposizione ai 3 fattori PCA mensili con soli 3 strumenti (es. futures su 2Y, 10Y, 20Y).
4. **Previsione:** modelli VAR o ARIMA si applicano ai 3 scores mensili anziché alle 20 variabili originali, con stime più stabili e interpretabili.

6. Conclusioni

- La PCA si applica alle **variazioni mensili centrate** X : la frequenza mensile elimina il rumore di breve periodo e rende i movimenti fattoriali visivamente inequivocabili.
- Lo strumento matematico è la **SVD di X** : stabile, esatta, interpretabile tramite il Teorema di Eckart-Young.
- Le **prime 3 componenti** spiegano il 95–99% della varianza anche con dati mensili: il risultato è robusto alla scelta della frequenza.
- I **loadings** rappresentano movimenti ben interpretabili della curva su tutte le maturity (livello, pendenza, curvatura); gli **scores mensili** sono leggibili e collegabili a eventi macroeconomici identificabili. Combinando questi valori opportunamente è possibile determinare la variazione storica della curva dei tassi, utilizzando al più tre componenti.

Riferimenti bibliografici

- [1] **Quarteroni, A., Saleri, F., Gervasio, P.** (2017). *Calcolo Scientifico*, 6a ed. Springer. Capitolo 6 per SVD e PCA.
- [2] **Burden, R.L., Faires, J.D.** (2016). *Numerical Analysis*, 10th ed. Cengage.
- [3] **Fabozzi, F.J.** (2012). *Fixed Income Mathematics*, 4th ed. McGraw-Hill. Per il contesto obbligazionario dei fattori PCA.
- [4] **Litterman, R., Scheinkman, J.** (1991). *Common Factors Affecting Bond Returns*. Journal of Fixed Income 1(1), 54–61. Articolo originale che identifica i 3 fattori (livello, pendenza, curvatura) nelle curve dei tassi USA.
- [5] **Rebonato, R.** (2004). *Volatility and Correlation: The Perfect Hedger and the Fox*, 2nd ed. Wiley Finance. Capitolo 7: analisi fattoriale delle curve dei tassi e applicazioni al risk management; motiva la PCA sui delta e non sui livelli per la coerenza con il calcolo del P&L.