

PCA sulle Curve dei Tassi di Interesse (ECB)

Teoria, Implementazione in R e Interpretazione Economica

Laboratorio di Calcolo Numerico — Laurea Triennale in Matematica Applicata
Università degli Studi di Verona
Anno Accademico 2026–2027

Indice

1	Introduzione e obiettivi	2
1.1	Il problema	2
1.2	Perché variazioni mensili?	2
1.3	Origine dei dati	2
1.4	Dataset	3
2	Prerequisiti matematici: SVD e approssimazione ottimale	3
2.1	Decomposizione ai Valori Singolari (SVD)	3
2.2	La norma di Frobenius	4
2.3	Il teorema di Eckart–Young–Mirsky: ottimalità della SVD troncata	4
2.4	PCA come SVD della matrice centrata	4
2.5	Nota numerica: perché usare la SVD diretta	5
3	Applicazione della PCA e SVD ai tassi di interesse ECB	5
3.1	Dati, aggregazione mensile e analisi esplorativa	5
3.1.1	Lettura, pulizia e aggregazione mensile	5
3.1.2	Struttura del dataset mensile	6
3.1.3	Grafico dei livelli mensili	7
3.1.4	Variazioni mensili: la matrice ΔR^{mens}	7
3.1.5	Matrice di correlazione mensile	9
3.2	PCA tramite SVD	9
3.2.1	Costruzione della matrice centrata e SVD	9
3.3	Interpretazione e ricostruzione	10
3.3.1	I loadings: forma dei fattori sulla curva	10
3.3.2	Interpretazione economica dei tre fattori	11
3.3.3	Gli scores mensili: la storia della politica monetaria BCE	11
3.3.4	Ricostruzione della curva	12
3.3.5	Codice R: ricostruzione e selezione dei mesi rappresentativi	14
3.4	Riepilogo dell’algoritmo completo	14
4	Calibrazione degli scores su una curva arbitraria	15
4.1	Proiezione ortogonale e pesi algebrici	15
4.2	Applicazione: ricostruzione curva EIOPA Aprile 2026	15
5	Applicazioni pratiche	17
6	Conclusioni	17

1. Introduzione e obiettivi

1.1. Il problema

La **curva dei tassi di interesse** (o struttura a termine) associa a ogni scadenza T un tasso di rendimento $r(T)$ per titoli privi di rischio. La curva cambia ogni giorno in risposta a decisioni di politica monetaria, aspettative di inflazione e fattori macroeconomici.

In questa dispensa analizziamo i dati mensili della curva dei tassi governativi dell'area Euro, pubblicati dalla Banca Centrale Europea (ECB), considerando le scadenze da 1 a 20 anni. L'obiettivo è comprendere e sintetizzare i principali movimenti osservati nella curva nel corso del tempo.

Monitorare direttamente tutte le scadenze della curva richiederebbe di gestire almeno 20 variabili (una per ogni maturity) e, in contesti come quello attuariale questo numero può salire a 40 o 50. Analizzare e interpretare così tante variabili è complesso e poco pratico.

Per questo motivo, è utile cercare una rappresentazione più compatta, ovvero individuare i *movimenti fondamentali* della curva che, combinati tra loro, spiegano la maggior parte delle variazioni osservate.

In questa dispensa presentiamo la **Principal Component Analysis (PCA)**, implementata tramite la **Singular Value Decomposition (SVD)**, che permette di identificare e quantificare le principali variazioni della curva dei tassi. Vedremo come, grazie a questa tecnica, sia possibile descrivere l'evoluzione della curva nel tempo utilizzando solo poche componenti principali, facilitando l'analisi e l'interpretazione dei dati.

Nella dispensa è inoltre riportato il codice utilizzato per l'elaborazione dei dati. A tal fine è stato impiegato il software statistico R, una piattaforma gratuita che mette a disposizione numerosi pacchetti specifici per l'analisi dei dati e la trattazione di queste tematiche.

1.2. Perché variazioni mensili?

Dal punto di vista dell'analisi economica, l'obiettivo non è quello di catturare movimenti di brevissimo periodo o dinamiche di microstruttura, bensì di descrivere l'evoluzione della curva dei rendimenti su orizzonti temporali più ampi, rilevanti per analisi prospettiche e di scenario. In questo contesto, l'utilizzo di variazioni giornaliere risulta più adatto ad applicazioni di trading o gestione operativa ad alta frequenza, mentre offre un contenuto informativo limitato per un'analisi strutturale dei fattori della curva.

Ci concentriamo dunque sull'analisi delle osservazioni mensili, che permettono di cogliere chiaramente i principali eventi macro-finanziari, quali la crisi di Lehman Brothers (2008), il “whatever it takes” di Draghi (2012), il Quantitative Easing della BCE (2015), lo shock pandemico (2020) e il ciclo di rialzi dei tassi del 2022.

1.3. Origine dei dati

I dati provengono dall'**ECB Data Portal**¹ e rappresentano la **spot rate curve** stimata dalla Banca Centrale Europea su un campione di titoli di Stato dell'area Euro con **rating AAA** (Germania, Paesi Bassi, Finlandia, ecc.).

Con il termine *spot rate* si intende, per ciascuna scadenza T , il tasso di interesse implicito nel prezzo di uno zero-coupon bond che paga un'unità di valuta al tempo T . Formalmente, indicando con $P(0, T)$ il prezzo oggi di tale titolo, lo spot rate $r(T)$ in capitalizzazione continua è definito da

$$P(0, T) = e^{-r(T)T}.$$

¹<https://data.ecb.europa.eu>, dataset *YC – Euro area yield curves*.

La curva degli spot rate rappresenta quindi la struttura a termine dei tassi di interesse priva di arbitraggio, dalla quale è possibile ricavare sia i prezzi di qualsiasi flusso cash-flow deterministico sia i tassi forward impliciti.

Poiché sul mercato non sono disponibili zero-coupon bond per tutte le scadenze, la curva viene ottenuta tramite una procedura di stima. In particolare, la BCE utilizza il **modello di Svensson**, una parametrizzazione flessibile della curva dei rendimenti che consente di interpolare e lisciare i dati osservati. I tassi sono espressi in capitalizzazione continua, in percentuale annua.

1.4. Dataset

I dati grezzi sono forniti nel file `pca_input_curves_1Y_20Y.xlsx` (foglio `PCA_Input`) con frequenza giornaliera. Per l'analisi PCA, i dati vengono aggregati a frequenza mensile selezionando l'ultima osservazione di ogni mese (dettagli e codice R nella Sezione 3.1.1).

2. Prerequisiti matematici: SVD e approssimazione ottimale

In questa sezione presentiamo gli strumenti matematici necessari per la PCA, organizzati attorno a una domanda centrale:

Il problema fondamentale

Data una matrice $X \in \mathbb{R}^{m \times n}$ (ad esempio le variazioni mensili della curva dei tassi), come possiamo rappresentarla in modo *compatto* usando solo $k \ll n$ “direzioni” fondamentali, perdendo la minima quantità possibile di informazione?

La risposta a questa domanda passa attraverso tre risultati:

1. la **SVD** fattorizza qualsiasi matrice in componenti ordinate per importanza;
2. il teorema di **Eckart–Young–Mirsky** garantisce che troncare la SVD alle prime k componenti dà la migliore approssimazione possibile di rango k ;
3. la **norma di Frobenius** usata in questo teorema coincide (a meno di costanti) con la *varianza totale*, quindi “miglior approssimazione” significa “massima varianza spiegata”.

2.1. Decomposizione ai Valori Singolari (SVD)

Teorema 2.1 (Esistenza e unicità della SVD). *Per ogni matrice $A \in \mathbb{R}^{m \times n}$ esistono:*

- una matrice ortogonale $U \in \mathbb{R}^{m \times m}$ (colonne = **vettori singolari sinistri**);
- una matrice ortogonale $V \in \mathbb{R}^{n \times n}$ (colonne = **vettori singolari destri**);
- una matrice diagonale $\Sigma \in \mathbb{R}^{m \times n}$ con elementi $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$ (**valori singolari**);

tali che $A = U\Sigma V^T$. I valori singolari sono unici; i vettori singolari sono unici a meno di segno quando i σ_i sono distinti.

Interpretazione geometrica. La SVD scompone l'azione di A in tre passi:

$$\mathbf{x} \xrightarrow{V^T} \text{rotazione} \xrightarrow{\Sigma} \text{scaling per asse} \xrightarrow{U} \text{rotazione}.$$

I valori singolari σ_i misurano quanto A “allunga” lungo ciascun asse principale: σ_1 è la direzione di massimo allungamento, σ_n quella di minimo. Nel contesto PCA:

- le colonne di V sono le **direzioni principali** (loadings);

- le colonne di U , scalate per σ_i , danno gli **scores**;
- σ_i^2 è proporzionale alla **varianza** lungo la i -esima direzione.

2.2. La norma di Frobenius

Definiamo la norma di **norma di Frobenius** come segue:

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\text{tr}(A^T A)}.$$

Proposizione 2.2 (Frobenius e valori singolari). *Per ogni matrice A con valori singolari $\sigma_1, \dots, \sigma_r$ (dove $r = \text{rk}(A)$):*

$$\|A\|_F^2 = \sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2. \quad (1)$$

2.3. Il teorema di Eckart–Young–Mirsky: ottimalità della SVD troncata

Teorema 2.3 (Eckart–Young–Mirsky, 1936). *Sia $A = U\Sigma V^T$ la SVD di A , e sia*

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = U_k \Sigma_k V_k^T$$

*la **SVD troncata** alle prime k componenti. Allora A_k è la **miglior approssimazione di rango k** in norma di Frobenius:*

$$A_k = \underset{\text{rk}(B) \leq k}{\text{argmin}} \|A - B\|_F.$$

Inoltre, l'errore di approssimazione è:

$$\|A - A_k\|_F^2 = \sigma_{k+1}^2 + \dots + \sigma_r^2. \quad (2)$$

2.4. PCA come SVD della matrice centrata

Consideriamo ora un dataset dove applicare la nostra SVD ed analisi.

Definizione 2.4 (Matrice centrata). Data $X \in \mathbb{R}^{m \times n}$ (righe = osservazioni, colonne = variabili), la **matrice centrata** è:

$$\tilde{X} = X - \mathbf{1}_m \bar{\mathbf{x}}^T,$$

dove $\bar{\mathbf{x}} \in \mathbb{R}^n$ è il vettore delle medie per colonna.

La varianza campionaria di $\tilde{X}$, è definita come:

$$\text{Var}_{\text{tot}} = \frac{1}{m-1} \sum_{i,j} \tilde{x}_{ij}^2 = \frac{\|\tilde{X}\|_F^2}{m-1}. \quad (3)$$

Quindi $\|\tilde{X}\|_F^2 = (m-1) \cdot \text{Var}_{\text{tot}}$, da (1) segue che la norma di Frobenius rappresenta la varianza totale, a meno di una costante.

Possiamo ora definire la Principal Component Analysis (PCA) calcolata sul set di osservazioni $\tilde{X}$.

Teorema 2.5 (Principal component Analysis). *Sia $\tilde{X} = U\Sigma V^T$ la SVD della matrice centrata. Allora:*

1. I **loadings** (direzioni principali) sono le colonne di V : $\mathbf{v}_1, \mathbf{v}_2, \dots$
2. Gli **scores** (coordinate nelle nuove direzioni) sono le righe di $U\Sigma$, cioè $\tilde{X}V$.
3. La varianza spiegata dalla componente i è $\sigma_i^2 / \sum_j \sigma_j^2$.

Considerando $k < n$ componenti principali, il teorema Per il Teorema 2.3 (Eckart–Young), $\tilde{X}_k$ è la miglior approssimazione di rango k di $\tilde{X}$ in norma di Frobenius, con errore residuo:

$$\|\tilde{X} - \tilde{X}_k\|_F^2 = \sigma_{k+1}^2 + \dots + \sigma_n^2. \quad (4)$$

Combinando (3) e (4), possiamo definire la **quota di varianza spiegata** dalle prime k componenti come:

$$\eta_k = \frac{\|\tilde{X}_k\|_F^2}{\|\tilde{X}\|_F^2} = \frac{\sigma_1^2 + \dots + \sigma_k^2}{\sigma_1^2 + \dots + \sigma_n^2} = 1 - \frac{\sigma_{k+1}^2 + \dots + \sigma_n^2}{\sigma_1^2 + \dots + \sigma_n^2} \in [0, 1]. \quad (5)$$

La s -esima riga di $\tilde{X}_k$ fornisce l'approssimazione centrata della variazione del mese s con sole k componenti:

$$\hat{\mathbf{x}}_s^{(k)} = \sum_{i=1}^k \alpha_{s,i} \mathbf{v}_i = V_k \boldsymbol{\alpha}_{s,k} \in \mathbb{R}^n, \quad \alpha_{s,i} = \sigma_i u_{s,i} = (U\Sigma)_{s,i}. \quad (6)$$

Aggiungendo il vettore delle variazioni medie $\bar{\boldsymbol{\delta}} \in \mathbb{R}^n$, sottratto prima della decomposizione SVD, si ottiene la variazione ricostruita nella scala originale:

$$\widehat{\Delta \mathbf{r}}_s^{(k)} = \bar{\boldsymbol{\delta}} + \sum_{i=1}^k \alpha_{s,i} \mathbf{v}_i = \bar{\boldsymbol{\delta}} + V_k \boldsymbol{\alpha}_{s,k}. \quad (7)$$

2.5. Nota numerica: perché usare la SVD diretta

Nota numerica (Condizionamento e stabilità). Un'alternativa alla SVD è calcolare gli autovalori della matrice di covarianza $C = \frac{1}{m-1} \tilde{X}^T \tilde{X}$. Tuttavia:

- Il **numero di condizionamento** di C è il quadrato di quello di $\tilde{X}$: $\kappa(C) = \kappa(\tilde{X})^2$.
- Per dati reali di tassi, $\kappa(\tilde{X}) \sim 10^2$ – 10^3 , quindi $\kappa(C) \sim 10^4$ – 10^6 .
- Un alto condizionamento significa che gli autovettori associati ai piccoli autovalori sono calcolati con scarsa precisione.

La **SVD diretta di $\tilde{X}$** evita questo problema: fornisce gli stessi loadings e scores, ma con stabilità numerica ottimale. In R, la funzione `svd()` implementa questa strategia.

3. Applicazione della PCA e SVD ai tassi di interesse ECB

In questa sezione applichiamo la teoria sviluppata nella sezione precedente alla curva dei tassi ECB. Il percorso si articola in quattro fasi: preparazione dei dati e analisi esplorativa, decomposizione tramite SVD, interpretazione economica dei fattori e ricostruzione della curva, infine un riepilogo dell'algoritmo completo con una panoramica delle principali applicazioni pratiche.

3.1. Dati, aggregazione mensile e analisi esplorativa

3.1.1. Lettura, pulizia e aggregazione mensile

Il codice seguente carica i dati giornalieri, li pulisce e li riduce all'ultima osservazione di ogni mese. Formalmente, la matrice mensile è:

$$R_{s,j}^{\text{mens}} = R_{t^*(s),j}, \quad t^*(s) = \max\{t : t \in \text{mese } s\},$$

dove s indicizza i mesi e $j \in \{1, \dots, 20\}$ le scadenze. La matrice risultante è $R^{\text{mens}} \in \mathbb{R}^{M \times 20}$ con $M \approx 260$ mesi.

Lettura e aggregazione mensile (lezione_pca_mensile.R)

```
library(data.table); library(openxlsx); library(lubridate); library(ggplot2)

curve_df <- as.data.table(
  read.xlsx("04_ecb_spot.xlsx", sheet = "PCA_Input"))

# ... parsing date e interpolazione NA (invariati rispetto alla versione giornaliera)

# ---- Aggregazione mensile -----
# floor_date("2022-10-17", "month") restituisce "2022-10-01"
# .SD[.N] seleziona l'ultima riga di ogni gruppo → fine mese effettivo
curve_df[, YM := floor_date(TIME_PERIOD, "month")]
monthly_dt <- curve_df[, .SD[.N], by = YM,
  .SDcols = c("TIME_PERIOD", maturity_cols)]
setorder(monthly_dt, YM)

# ---- Matrici di lavoro -----
R_mat_m <- as.matrix(monthly_dt[, ..maturity_cols]) # M x n
dates_m <- monthly_dt$YM # date mese (M)
Delta_R_m <- diff(R_mat_m) # (M-1) x n
dates_delta_m <- dates_m[-1]
```

Osservazione. La scelta di prendere l'*ultima* osservazione (e non la media mensile) è standard nella gestione del rischio di tasso: riflette il prezzo al quale si chiude il mese e sul quale si calcolano i P&L mensili dei portafogli obbligazionari.

3.1.2. Struttura del dataset mensile

Colonna	Contenuto
YM	Primo giorno del mese (es. 2022-10-01)
TIME_PERIOD	Data effettiva di fine mese (ultima giornata BCE)
1Y, ..., 20Y	Tasso (%) alla scadenza corrispondente

3.1.3. Grafico dei livelli mensili




Figura 1: Curve dei tassi ECB in tre mesi rappresentativi del campione. L'asse x indica la scadenza in anni, l'asse y il tasso in %.

3.1.4. Variazioni mensili: la matrice ΔR^{mens}

La PCA si applica alle *variazioni* della curva, non ai livelli:

$$(\Delta R^{\text{mens}})_{s,j} = R_{s,j}^{\text{mens}} - R_{s-1,j}^{\text{mens}}, \quad s = 2, \dots, M, \quad j = 1, \dots, n.$$

Applicare la PCA ai livelli R^{mens} sarebbe tecnicamente possibile, ma produrrebbe risultati statisticamente non affidabili per tre ragioni:

1. **Non stazionarietà.** I tassi di interesse sono spesso modellati come moti browniani con drift e dunque applicare la PCA a una serie non stazionaria significa decomporre la varianza di un processo che non ha media e varianza costanti nel tempo: i loadings ottenuti dipenderebbero fortemente dal periodo campionario e non sarebbero generalizzabili. Le variazioni ΔR sono invece stazionarie (o quasi-stazionarie), e la PCA è uno strumento progettato per dati stazionari [4].
2. **Dominanza del livello medio.** Se si applica la PCA ai livelli, la prima componente cattura quasi interamente la traiettoria storica media dei tassi (la discesa dal 1995 al 2020 e la risalita del 2022): non un *movimento* della curva, ma la sua *tendenza secolare*. Questo non è informativo per la gestione del rischio, che si preoccupa di quanto può muoversi la curva nel prossimo mese, non di dove si trovava vent'anni fa.
3. **Interpretazione in termini di rischio.** Nella gestione di portafoglio e nel calcolo del VaR, l'input naturale è la variazione di valore (P&L), che dipende dalle variazioni dei tassi $\Delta r(T)$, non dai loro livelli. I tre fattori PCA estratti da ΔR — livello, pendenza, curvatura — hanno quindi un significato operativo diretto: uno shock di +1 sull' i -esimo score corrisponde a una deformazione specifica e quantificata della curva, direttamente raccordabile con uno scenario di stress [5].

Nota pratica. In letteratura si trovano a volte PCA sui livelli (es. per costruire curve parametriche sintetiche). In quel contesto l'obiettivo è diverso: si vuole approssimare la *forma* della curva, non i suoi movimenti. Per l'analisi del rischio e per la scomposizione fattoriale del P&L, la PCA sulle variazioni è lo standard consolidato fin da Litterman & Scheinkman [4].

Le variazioni mensili hanno un range tipico di **20–80 punti base** nei periodi normali, e fino a **150–200 pb** negli episodi di shock monetario. Questo ordine di grandezza le rende direttamente interpretabili e confrontabili con le decisioni di politica monetaria BCE (ad es. rialzo di 75 pb a ottobre 2022).




Figura 2: **Distribuzione delle variazioni mensili** $\Delta R^{\text{mens}}(T_j)$ per ciascuna scadenza, espressa in punti base (1 pb = 0.01%). Rispetto alla versione giornaliera, le distribuzioni sono nettamente più informative: le mediane si discostano visibilmente da zero nei periodi di trend (es. 2022), gli IQR catturano la volatilità ciclica tipica di ogni scadenza, e la struttura del segnale domina il rumore. La variabilità è maggiore alle scadenze intermedie–lunghe, indice del fatto che i movimenti di curvatura e pendenza si manifestano principalmente sul tratto 2–10 anni.

3.1.5. Matrice di correlazione mensile




Figura 3: Correlazione tra variazioni mensili visualizzata in due modi complementari: heat-map (sinistra) e superficie a barre 3D (destra).

3.2. PCA tramite SVD

3.2.1. Costruzione della matrice centrata e SVD

Applicando il Teorema 2.5 alla matrice mensile:

Centraggio e SVD su dati mensili

```
X_m      <- scale(Delta_R_m, center = TRUE, scale = FALSE)
sv_m     <- svd(X_m)

sing_vals <- sv_m$d
expl_var  <- sing_vals^2 / sum(sing_vals^2)
cum_var   <- cumsum(expl_var)
k_star    <- which(cum_var >= 0.95)[1] # componenti per 95%
```




Figura 4: Varianza per componente e varianza cumulata. Barre blu: varianza individuale per componente; linea rossa: varianza cumulata; tratteggio grigio: soglia 95%. Il numero k^* di componenti necessarie per il 95% è tipicamente 2 o 3.

Nel seguito, in linea con la prassi consolidata in letteratura (si veda la Sezione 3.3), si adotta $k^* = 3$: le prime tre componenti principali spiegano il $\eta_3 = 99.51\%$ della varianza totale del campione, una quota che rende trascurabile il contributo delle componenti residue.

3.3. Interpretazione e ricostruzione

3.3.1. I loadings: forma dei fattori sulla curva

I loadings $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3 \in \mathbb{R}^n$ rappresentano le direzioni principali rispetto cui decomporre la variazione mensile dei tassi di interesse.




Figura 5: Loadings delle prime tre componenti in funzione della scadenza (anni). PC1 piatta (livello), PC2 monotona (pendenza), PC3 a gobba (curvatura).

3.3.2. Interpretazione economica dei tre fattori

Fattore	Tipo	Forma del loading	Interpretazione	Var. tipica
PC1	Livello	Stesso segno e valore simile per tutte le scadenze	Shift parallelo: tutti i tassi salgono o scendono insieme	70–80%
PC2	Pendenza	Un cambio di segno: negativo (breve) / positivo (lungo)	Rotazione: tassi brevi e lunghi in direzioni opposte	10–15%
PC3	Curvatura	Due cambi di segno: positivo agli estremi, negativo al centro	Butterfly: il ventre si muove in senso opposto agli estremi	3–7%

3.3.3. Gli scores mensili: la storia della politica monetaria BCE

Dopo la decomposizione $\tilde{X} = U\Sigma V^T$, la matrice degli **scores** è $A = U\Sigma \in \mathbb{R}^{(M-1) \times n}$, con $A_{s,i} = \sigma_i u_{s,i}$. Lo score $\alpha_{s,i}$ misura di quanto la curva si è mossa nel mese s nella direzione del loading $\mathbf{v}_i$: un valore grande (in modulo) indica che quel fattore ha dominato il movimento; un valore vicino a zero indica che il fattore era inattivo.




Figura 6: Scores mensili PC1, PC2, PC3 con marcatura degli eventi macroeconomici principali (linee tratteggiate grigie).

La Figura 6 riporta l'evoluzione temporale dei tre scores. **PC1 (livello)**: i picchi negativi corrispondono a crisi in cui tutti i tassi scendono in blocco (Lehman 2008, COVID 2020); il picco positivo del 2022 è il più grande del campione e riflette il ciclo di rialzi BCE da luglio 2022 a settembre 2023, il più aggressivo dalla creazione dell'euro. **PC2 (pendenza)**: cattura i cambi di forma; nel 2022 la curva si *invertiva* (breve sopra lungo) mentre i tassi salivano — PC2 segnala la rotazione indipendentemente dal livello. **PC3 (curvatura)**: movimenti più piccoli ma identificabili; il QE BCE (2015–2018) ha prodotto una curvatura distintiva comprimendo il ventre della curva. Con dati giornalieri tutti questi segnali sarebbero sepolti nel rumore.

3.3.4. Ricostruzione della curva

La variazione mensile del mese s si ricostruisce come combinazione lineare dei loadings, pesati dagli scores:

$$\hat{\Delta r}_s^{(k)} = \underbrace{\bar{\delta}}_{\text{media}} + \underbrace{\alpha_{s,1} \mathbf{v}_1}_{\text{livello}} + \underbrace{\alpha_{s,2} \mathbf{v}_2}_{\text{pendenza}} + \cdots + \alpha_{s,k} \mathbf{v}_k \quad (8)$$

dove $\bar{\delta} \in \mathbb{R}^n$ è il vettore delle variazioni medie (sottratto prima della decomposizione SVD e aggiunto per riportare nella scala originale), $\alpha_{s,i} = (U\Sigma)_{s,i}$ è lo score, e $\mathbf{v}_i$ il loading. Consideriamo ora come esempio, tre mesi: Ottobre 2004 (primo mese), Maggio 2015 (centrale) e Dicembre 2025 (ultimo) per verificare la qualità della ricostruzione su periodi diversi del campione.




Figura 7: Variazione mensile reale vs. ricostruita con $k = 3$ componenti nei tre mesi selezionati (primo, centrale, ultimo). L'asse y è in punti base.

In ciascun pannello della Figura 7, la curva osservata e quella ricostruita sono molto vicine: la PCA a 3 fattori cattura i movimenti principali della curva su tutta la storia del campione. Le discrepanze residue sono associate alle componenti dalla quarta in poi, che spiegano una quota limitata della varianza totale.

Per capire il contributo di ciascuna componente, è utile osservare come la curva si ricostruisce aggiungendo un fattore alla volta. Come esempio concreto utilizziamo **maggio 2025**: un mese recente in cui la curva BCE ha mostrato un movimento non banale, con una componente di pendenza apprezzabile oltre al consueto shift parallelo.




Figura 8: Ricostruzione progressiva della variazione mensile della curva BCE per maggio 2025, aggiungendo una componente alla volta. La curva nera è la variazione reale osservata (in punti base).

La Figura 8 mostra come ogni fattore contribuisce alla ricostruzione. $k = 1$ (**+livello**): aggiunge lo shift parallelo dominante — già la maggior parte del movimento viene spiegata. $k = 2$ (**+pendenza**): corregge la rotazione breve-lungo, catturando la differenza di movimento tra scadenze corte e lunghe. $k = 3$ (**+curvatura**): affina il profilo del ventre, riducendo ulteriormente il residuo. La percentuale tra parentesi in legenda è la varianza cumulata spiegata sull'intero campione da quella componente.

3.3.5. Codice R: ricostruzione e selezione dei mesi rappresentativi

Selezione automatica dei mesi: primo, centrale, ultimo

```
k_rec      <- 3L
scores_k_m <- sv_m$u[, 1:k_rec] %*% diag(sv_m$d[1:k_rec], nrow=k_rec)
loadings_k_m <- sv_m$v[, 1:k_rec]
X_hat_m     <- scores_k_m %*% t(loadings_k_m)
rmse_m      <- sqrt(mean((X_m - X_hat_m)^2))

# Mesi selezionati: primo, centrale, ultimo
sel_month_idx <- c(1L, ceiling(nrow(Delta_R_m) / 2), nrow(Delta_R_m))
sel_month_ym  <- dates_delta_m[sel_month_idx]

# Confronto reale vs ricostruita sui 3 mesi
mean_delta_m <- attr(X_m, "scaled:center")
delta_reale  <- Delta_R_m[sel_month_idx, ]
delta_rec    <- X_hat_m[sel_month_idx, ] +
  matrix(mean_delta_m, nrow =
    length(sel_month_idx),
    ncol = ncol(X_m),
    byrow = TRUE)
```

3.4. Riepilogo dell'algoritmo completo

PCA mensile della curva dei tassi BCE (in R)

```
# INPUT: curve_df con colonne TIME_PERIOD, 1Y, ..., 20Y

# 1. Aggregazione mensile (ultima osservazione di ogni mese)
curve_df[, YM := floor_date(TIME_PERIOD, "month")]
monthly_dt <- curve_df[, .SD[.N], by = YM, .SDcols = c("TIME_PERIOD", maturity_cols)]

# 2. Matrice dei livelli e variazioni mensili
R_mat_m <- as.matrix(monthly_dt[, ..maturity_cols]) # M x n
Delta_R_m <- diff(R_mat_m) # (M-1) x n

# 3. Centraggio per colonna
X_m <- scale(Delta_R_m, center = TRUE, scale = FALSE)

# 4. SVD della matrice centrata
sv_m <- svd(X_m) # sv_m$u, sv_m$d, sv_m$v

# 5. Varianza spiegata
expl_var <- sv_m$d^2 / sum(sv_m$d^2)
cum_var <- cumsum(expl_var)
k_star <- which(cum_var >= 0.95)[1]

# 6. Loadings e scores
V_m <- sv_m$v
scores_m <- sv_m$u[, 1:3] %*% diag(sv_m$d[1:3], nrow = 3)

# 7. Ricostruzione sui mesi primo/centrale/ultimo
X_hat_m <- sv_m$u[, 1:3] %*% diag(sv_m$d[1:3], nrow=3) %*% t(sv_m$v[, 1:3])
sel_month_idx <- c(1L, ceiling(nrow(Delta_R_m) / 2), nrow(Delta_R_m))
```

4. Calibrazione degli scores su una curva arbitraria

Una volta stimata la matrice dei loadings V dalla PCA storica, è possibile *proiettare* qualsiasi nuova curva dei tassi $\mathbf{y} \in \mathbb{R}^n$ sullo spazio generato dalle prime k componenti principali, ottenendo k **pesi** (scores) e una **ricostruzione approssimata**. Con $k = n$ (base completa) la ricostruzione è esatta.

4.1. Proiezione ortogonale e pesi algebrici

Siano $\mathbf{v}_1, \dots, \mathbf{v}_n \in \mathbb{R}^n$ i vettori colonna di V — le colonne ortonormali della SVD di $\tilde{X}$, cioè i **loadings PCA**. Essi formano una base ortonormale di $\mathbb{R}^n$:

$$V^T V = I_n, \quad V \in \mathbb{R}^{n \times n}.$$

Dati i primi $k \leq n$ loadings $V_k = [\mathbf{v}_1 \mid \dots \mid \mathbf{v}_k] \in \mathbb{R}^{n \times k}$, la ricostruzione di $\mathbf{y}$ con k componenti si ottiene in due passi:

Proiezione su k componenti principali

Passo 1 — Calcolo dei pesi (scores): si proietta $\mathbf{y}$ su ciascuna direzione principale:

$$\boldsymbol{\alpha}_k = V_k^T \mathbf{y} = \begin{pmatrix} \mathbf{v}_1^T \mathbf{y} \\ \vdots \\ \mathbf{v}_k^T \mathbf{y} \end{pmatrix} \in \mathbb{R}^k.$$

Ogni componente $\alpha_i = \mathbf{v}_i^T \mathbf{y}$ è il prodotto scalare tra $\mathbf{y}$ e il loading $\mathbf{v}_i$: misura “quanto” di $\mathbf{y}$ sta nella direzione i -esima.

Passo 2 — Ricostruzione: si combinano linearmente i loadings con i pesi appena calcolati:

$$\hat{\mathbf{y}}^{(k)} = V_k \boldsymbol{\alpha}_k = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k \in \mathbb{R}^n.$$

Formula compatta. Sostituendo $\boldsymbol{\alpha}_k = V_k^T \mathbf{y}$ nella ricostruzione:

$$\hat{\mathbf{y}}^{(k)} = V_k (V_k^T \mathbf{y}) = (V_k V_k^T) \mathbf{y}.$$

La matrice $P_k = V_k V_k^T \in \mathbb{R}^{n \times n}$ è il **proiettore ortogonale** sullo spazio generato dalle prime k colonne di V .

Osservazione. Per $k = n$ vale $V_n V_n^T = I_n$ (base completa), quindi $\hat{\mathbf{y}}^{(n)} = \mathbf{y}$ e l'errore di ricostruzione è zero. La curva viene recuperata *esattamente* combinando tutti i loadings.

4.2. Applicazione: ricostruzione curva EIOPA Aprile 2026

Consideriamo la curva dei livelli EIOPA di Aprile 2026:

Scadenza	Tasso (%)	Scadenza	Tasso (%)
1Y	2.680	11Y	3.025
2Y	2.752	12Y	3.072
3Y	2.748	13Y	3.106
4Y	2.753	14Y	3.134
5Y	2.783	15Y	3.166
6Y	2.818	16Y	3.186
7Y	2.858	17Y	3.195
8Y	2.904	18Y	3.197
9Y	2.944	19Y	3.195
10Y	2.998	20Y	3.192

Calcoliamo i pesi $\alpha_k = V_k^T \mathbf{y}$ per $k = 1, \dots, 20$ e le relative ricostruzioni. Calcoliamo i pesi $\alpha_k = V_k^T \mathbf{y}$ per $k = 1, \dots, 20$ e le relative ricostruzioni.

Il Grafico A (Figura 9) confronta la curva originale con due ricostruzioni: $k = 3$ (approssimazione con i tre fattori economici) e $k = 20$ (base completa, ricostruzione esatta). Già con sole 3 componenti la forma della curva è catturata; con $k = 20$ la curva ricostruita coincide esattamente con l'originale.

Il Grafico B (Figura 10) mostra l'errore ε_k in punti base su scala logaritmica, per $k = 1, \dots, 19$. La scala log evidenzia il tasso di convergenza: l'errore decresce rapidamente nelle prime componenti e diventa trascurabile oltre $k = 10$. Per $k = 20$ l'errore è numericamente zero (non mostrato perché non rappresentabile in scala log).




Figura 9: **Grafico A — Ricostruzione della curva dei livelli.** Curva nera con punti: originale. Curva arancio tratteggiata: ricostruzione con $k = 3$ componenti. Curva verde puntinata: ricostruzione con $k = 20$ (base completa).




Figura 10: **Grafico B — Convergenza dell'errore (scala logaritmica)**. Errore $\varepsilon_k = \|\hat{\mathbf{y}}^{(k)} - \mathbf{y}\|_2$ in punti base per $k = 1, \dots, 19$. I punti rossi annotati indicano l'errore e la riduzione percentuale rispetto a $k = 1$ per $k = 3$ e $k = 10$.

5. Applicazioni pratiche

1. **Compressione:** il dataset mensile (260 righe $\times$ 20 colonne) si riduce a 3 serie temporali di scores con perdita di informazione inferiore al 5%.
2. **Scenari di stress mensili:** uno shock di $+\sigma_1$ sul fattore livello simula una decisione BCE di rialzo di circa 25–50 pb; identifica immediatamente la sensibilità di un portafoglio obbligazionario.
3. **Hedging fattoriale:** invece di coprirsi contro 20 movimenti indipendenti, si gestisce l'esposizione ai 3 fattori PCA mensili con soli 3 strumenti (es. futures su 2Y, 10Y, 20Y).
4. **Previsione:** modelli VAR o ARIMA si applicano ai 3 scores mensili anziché alle 20 variabili originali, con stime più stabili e interpretabili.

6. Conclusioni

- La PCA si applica alle **variazioni mensili centrate** X : la frequenza mensile elimina il rumore di breve periodo e rende i movimenti fattoriali visivamente inequivocabili.
- Lo strumento matematico è la **SVD di X** : stabile, esatta, interpretabile tramite il Teorema di Eckart-Young.
- Le **prime 3 componenti** spiegano il 95–99% della varianza anche con dati mensili: il risultato è robusto alla scelta della frequenza.
- I **loadings** rappresentano movimenti ben interpretabili della curva su tutte le maturity (livello, pendenza, curvatura); gli **scores mensili** sono leggibili e collegabili a eventi macroeconomici identificabili. Combinando questi valori opportunamente è possibile determinare la variazione storica della curva dei tassi, utilizzando al più tre componenti.

Riferimenti bibliografici

- [1] **Quarteroni, A., Saleri, F., Gervasio, P.** (2017). *Calcolo Scientifico*, 6a ed. Springer. Capitolo 6 per SVD e PCA.

- [2] **Burden, R.L., Faires, J.D.** (2016). *Numerical Analysis*, 10th ed. Cengage.
- [3] **Fabozzi, F.J.** (2012). *Fixed Income Mathematics*, 4th ed. McGraw-Hill. Per il contesto obbligazionario dei fattori PCA.
- [4] **Litterman, R., Scheinkman, J.** (1991). *Common Factors Affecting Bond Returns*. Journal of Fixed Income 1(1), 54–61. Articolo originale che identifica i 3 fattori (livello, pendenza, curvatura) nelle curve dei tassi USA.
- [5] **Rebonato, R.** (2004). *Volatility and Correlation: The Perfect Hedger and the Fox*, 2nd ed. Wiley Finance. Capitolo 7: analisi fattoriale delle curve dei tassi e applicazioni al risk management; motiva la PCA sui delta e non sui livelli per la coerenza con il calcolo del P&L.
- [6] **ECB Data Portal** — <https://data.ecb.europa.eu>: dataset YC.B.U2.EUR.4F.G_N_A.SV_C_YM.SR_nY per le spot rate BCE AAA.